

Assistant radiologue virtuel responsable

Prototype pédagogique d'IA multimodale pour l'analyse prudente
de radiographies thoraciques

Rapport final

Filière Data / Intelligence artificielle — Solution Delivery

École EFREI Paris

Année académique 2025-2026

Modèle évalué google/medgemma-4b-it (4-bit, QLoRA-ready)

Position non clinique. Ce prototype n'est pas un dispositif médical. Il ne doit jamais être utilisé pour diagnostiquer, trier ou orienter un patient. Toute sortie est un résultat expérimental devant être vérifié par un professionnel qualifié.

Table des matières

1 Périmètre et jeu de données 2

1.1 Objectif et périmètre 2

1.2 Jeu de données 2

2 Architecture et baseline reproductible 2

2.1 Chaîne de traitement 2

2.2 Modèle et baseline 2

3 Amélioration mesurée : itération des prompts 2

3.1 v1 — trop permissif : faux négatifs surconfiants 3

3.2 v2 — trop strict : le détecteur qui « crie au loup » 3

3.3 v3 — l’équilibre : diagnostic puis correction 4

4 Évaluation et analyse d’erreurs 4

4.1 Protocole et métriques 4

4.2 Taxonomie d’erreurs 4

4.3 Registre d’erreurs (extrait) 5

5 Éthique, sécurité et limites 5

5.1 Garde-fous fonctionnels 5

5.2 Limites documentées 5

6 Références techniques et licences 5

7 Conclusion 6

1. Périmètre et jeu de données

1.1. Objectif et périmètre

Le projet développe une application web qui reçoit une radiographie thoracique frontale et retourne une sortie JSON structurée : qualité de l'image, classe prédite parmi {**normal**, **suspected_opacity**, **uncertain**}, confiance, observations visuelles, justification courte, limites et avertissement obligatoire. Le projet ne vise pas le diagnostic : il vise l'apprentissage d'une démarche d'ingénierie responsable — périmètre restreint, baseline reproductible, métriques, journaux, garde-fous et limites documentées.

1.2. Jeu de données

L'évaluation porte sur un jeu synthétique de 30 images, réparties de façon équilibrée (10 **normal**, 10 **suspected_opacity**, 10 **uncertain**). Ces images sont générées procéduralement (`source = synthetic_toy`) et ne contiennent aucune donnée patient réelle. Le choix des données synthétiques est explicitement autorisé par le cahier des charges (« *Synthétiques ou publiques, autorisées et dé-identifiées* »).

Limite fondamentale assumée. Les images ne sont pas de vraies radiographies. Les scores rapportés mesurent le comportement du *pipeline* et la *sensibilité aux prompts*, non une performance clinique. Un score élevé sur ce jeu ne constitue en aucun cas une validation médicale.

2. Architecture et baseline reproductible

2.1. Chaîne de traitement

La chaîne est volontairement découpée pour rester exécutable sans GPU en démonstration :

Image → *Preprocessing* → *MedGemma4B(hors – ligne, 4 – bit)* → *Guardrails* → *JSON* → *UI/SQLite*

L'inférence lourde du modèle multimodal est exécutée *une seule fois* en traitement par lot sur GPU (Colab T4, quantification 4-bit via BitsAndBytes). Les prédictions sont mises en cache (`eval/cached_predictions/*.json`). L'API FastAPI, les interfaces Streamlit/Gradio et le protocole d'évaluation ne rechargent jamais le modèle : ils lisent le cache. Ce découplage rend toute la surface évaluée reproductible sur CPU et déterministe (décodage glouton, `do_sample=False`).

2.2. Modèle et baseline

La baseline applique un prompt simple à MedGemma 4B. Sur le jeu synthétique, elle atteint une exactitude de **80,0 %** et un macro-F1 de **78,0 %**, avec 100 % de sorties JSON valides et 100 % d'avertissements présents. Sa faiblesse principale est une sensibilité aux opacités de seulement **40 %** (6 opacités sur 10 classées à tort **normal**).

3. Amélioration mesurée : itération des prompts

Le cœur de ce travail est une itération d'ingénierie *mesurée* à chaque étape. Trois variantes de prompt ont été comparées à la baseline sur les mêmes 30 images. Le résultat central est qu'une formulation « prudente » plausible peut rendre le système *plus dangereux* : seule la mesure le révèle.

Version	Exactitude	Macro-F1	Sensib. opacité	Faux négatifs	Taux incert.
Baseline	80,0 %	78,0 %	40 %	6	33,3 %
v1 (strict)	66,7 %	55,6 %	0 %	10	33,3 %
v2 (sur-prudent)	36,7 %	25,6 %	100 %	0	33,3 %
v3 (équilibré)	86,7 %	86,9 %	90 %	1	26,7 %

TABLE 1 – Comparaison des quatre stratégies de prompt (30 cas synthétiques).




FIGURE 1 – Trajectoire des métriques au fil de l’itération. La v3 domine la baseline sur tous les axes.

3.1. v1 — trop permissif : faux négatifs surconfiants

Le prompt v1 ajoutait une consigne stricte invitant à considérer qu’une anomalie apparente pouvait résulter d’un artefact (projection, rotation, exposition). L’intention était la prudence. L’effet mesuré fut l’inverse : le modèle a utilisé cette consigne pour *écarter* les opacités et conclure à un **normal** confiant. Sur les cas concernés, la confiance est *montée* de 0,70 à 0,95 tout en devenant fausse — une miscalibration caractéristique. La sensibilité aux opacités s’est effondrée à 0 % (10 faux négatifs sur 10), soit l’erreur la plus dangereuse en contexte de dépistage.

3.2. v2 — trop strict : le détecteur qui « crie au loup »

En réaction, le prompt v2 imposait un biais de sécurité fort (« ne jamais rater une anomalie »). La sensibilité aux opacités atteint alors 100 % et les faux négatifs tombent à 0, mais au prix d’un effondrement de la précision : le modèle classe presque toutes les images comme **suspected_opacity** ou **uncertain**, y compris les 10 images réellement **normal** (précision **normal** nulle). Un détecteur qui alarme sur tout est aussi inutile qu’un détecteur qui n’alarme jamais.

3.3. v3 — l'équilibre : diagnostic puis correction

Le prompt v3 applique des règles *symétriques* : le doute est routé vers **uncertain** (jamais vers un **normal** confiant), mais une image manifestement saine peut redevenir **normal**. Une anomalie visible ne peut plus être « expliquée » en **normal**, sans que cela impose pour autant de tout signaler. Résultat : la v3 **dépasse la baseline sur toutes les métriques** — exactitude 86,7 %, macro-F1 86,9 % — tout en ramenant les faux négatifs de 6 à 1 et la sensibilité aux opacités de 40 % à 90 %.




FIGURE 2 – Matrices de confusion des quatre versions (lignes = vérité, colonnes = prédiction). On lit directement les deux modes d'échec (v1 : tout en **normal**; v2 : rien en **normal**) et la convergence de la v3.

Leçon d'ingénierie. L'arc $\text{baseline} \rightarrow \text{v1} \rightarrow \text{v2} \rightarrow \text{v3}$ montre qu'un prompt « de sécurité » plausible a silencieusement dégradé la sûreté clinique. La fluidité du texte produit ne garantit pas la correction : seule la mesure systématique a permis de diagnostiquer chaque échec et de converger vers un compromis défendable.

4. Évaluation et analyse d'erreurs

4.1. Protocole et métriques

L'évaluation calcule exactitude, macro-F1, sensibilité (**suspected_opacity**), spécificité (**normal**), taux de JSON valide, taux d'avertissement, taux d'incertitude et latence. Les runs sont journalisés en SQLite. La commande `python eval/run_evaluation.py -mode improved_v3` rejoue l'ensemble sur CPU.

4.2. Taxonomie d'erreurs

Code	Signification
FN	Faux négatif — anomalie présente prédite normal
FP	Faux positif — image normale prédite suspecte
UA	Incertitude acceptable / cas ambigu forcé
JF	Erreur de format JSON
HT	Hallucination textuelle (signe non visible mentionné)

TABLE 2 – Taxonomie utilisée dans le registre d'erreurs.

4.3. Registre d'erreurs (extrait)

Le registre complet (`eval/error_register.csv`) documente 10 cas commentés : les 4 erreurs résiduelles de la v3 et 6 cas d'ablation illustrant les modes d'échec de v1 et v2. Les erreurs résiduelles de la v3 sont la tension naturelle du compromis : une opacité encore manquée (`CXR_SYN_017`), une image normale sur-signalée (`CXR_SYN_010`) et deux cas ambigus poussés vers `suspected_opacity` plutôt que `uncertain`.

5. Éthique, sécurité et limites

5.1. Garde-fous fonctionnels

Chaque sortie passe par des garde-fous : validation stricte du schéma JSON, avertissement non clinique forcé sur 100 % des sorties, règle d'incertitude (repli vers **uncertain** en cas de doute ou de faible confiance), et journalisation des prompts, modèles, sorties et latences.

Avertissement obligatoire (présent dans l'UI, le JSON, le README et la soutenance) :

Prototype pédagogique. Non destiné au diagnostic. Validation par un professionnel qualifié requise.

5.2. Limites documentées

- **Données synthétiques.** Les images ne sont pas cliniques ; les scores ne mesurent que le pipeline et la sensibilité aux prompts.
- **Petit échantillon.** 30 images, 10 par classe : les valeurs sont illustratives, pas statistiquement robustes.
- **Confiance non calibrée.** Le modèle produit des valeurs de confiance peu variées (souvent 0,95 ou 0,20), non fiables comme probabilités.
- **Sensibilité au prompt.** Démontrée quantitativement : un changement de formulation fait varier l'exactitude de 36,7 % à 86,7 %.
- **Validation indépendante requise** pour tout usage réel.

6. Références techniques et licences

Modèle google/medgemma-4b-it (instruction-tuned).

Architecture variante Gemma 3 avec encodeur d'image SigLIP pré-entraîné sur des données médicales dé-identifiées, dont des radiographies thoraciques.

Accès modèle sous accès contrôlé (*gated*) sur Hugging Face ; connexion et acceptation des conditions requises.

Licence / conditions *Health AI Developer Foundations terms of use*.

Restrictions d'usage recherche et éducation ; non destiné au diagnostic ; non validé comme dispositif médical.

Code du dépôt licence MIT ; les datasets et modèles externes conservent leurs licences propres.

Conformément au cahier des charges, aucune donnée patient réelle n'a été utilisée ni commitée. Les extensions avancées (LoRA/QLoRA, MIMIC-CXR, CheXpert) n'ont pas été mobilisées ; elles sont documentées comme pistes COULD nécessitant un dataset réel sous accès contrôlé.

7. Conclusion

Le prototype démontre une méthode plutôt qu'une prouesse : périmètre restreint, baseline reproductible, garde-fous, évaluation chiffrée et analyse d'erreurs. Son apport principal est l'itération mesurée des prompts, qui établit empiriquement que la prudence *doit être mesurée* et non supposée. La version finale (v3) est prudente, défendable et documentée — ce que le cahier des charges valorise davantage qu'une solution spectaculaire mais infalsifiable.